

Prof. Osmar de Oliveira Braz Junior

Universidade do Estado de Santa Catarina – UDESC

Tópicos Especiais I – Tecnólogo em Análise e Desenvolvimento de Sistemas

Polo - Tubarão

15/06/2026

AD2 - Avaliação a Distância 2

Link do GitHub Repositório pessoal com os notebooks

[Kaky65/Topicos-Especiais-I: AD1 - Avaliação a Distancia 1](#)

[Kaky65/Topicos-Especiais-1: Avaliação a distância 2 - Parte 2](#)

2.1 Análise do conjunto de dados

5.1.4 Carregamento da lista com os dados dos arquivos e postagging

	id	sentencas	documento
12	13	[A colaboração entre setores público e privad...	A colaboração entre setores público e privado ...
15	16	[A cultura de segurança deve ser incorporada ...	A cultura de segurança deve ser incorporada em...
11	12	[Empresas inovadoras investem em inteligência...	Empresas inovadoras investem em inteligência a...
35	36	[A segurança cibernética deve ser vista como ...	A segurança cibernética deve ser vista como re...
25	26	[A formação de profissionais especializados e...	A formação de profissionais especializados em ...

	id	pos_documento
35	36	[[['A', 'segurança', 'cibernética', 'deve', 's...
24	25	[[['A', 'cooperação', 'internacional', 'é', 'f...
21	22	[[['A', 'criptografia', 'é', 'uma', 'das', 'fe...
36	37	[[['A', 'confiança', 'digital', 'é', 'construí...
0	1	[[['A', 'segurança', 'cibernética', 'tornou-se...

	id	ner_documento
34	35	[[0, []]]
35	36	[[0, []]]
13	14	[[0, []]]
25	26	[[0, []]]
31	32	[[0, []]]

	sentencas	documento
id		
1	[A segurança cibernética tornou-se um dos pila...	A segurança cibernética tornou-se um dos pilar...
2	[Com a expansão da internet e a digitalização ...	Com a expansão da internet e a digitalização d...
3	[Empresas de todos os portes enfrentam desafio...	Empresas de todos os portes enfrentam desafios...
4	[A conscientização dos usuários é tão importan...	A conscientização dos usuários é tão important...
5	[A educação digital deve ser vista como priori...	A educação digital deve ser vista como priorid...

	pos_documento
id	
1	[[[A, segurança, cibernética, tornou-se, um, d...
2	[[[Com, a, expansão, da, internet, e, a, digit...
3	[[[Empresas, de, todos, os, portes, enfrentam,...
4	[[[A, conscientização, dos, usuários, é, tão, ...
5	[[[A, educação, digital, deve, ser, vista, com...

	ner_documento
id	
1	[[0, []]]
2	[[0, [['internet', 'MISC', 18, 26]]]]
3	[[0, []]]
4	[[0, []]]
5	[[0, []]]

Converte a lista das pos tagging das palavras em um dataframe

	id	sentenca	palavra	pos
1123	34	0	tão	ADV
1183	36	0	digital	ADJ
17	1	0	cada	NOUN
993	29	0	com	ADP
937	27	0	e	CCONJ

Converte a lista das entidades das palavras em um datafram

	id	sentenca	entidade	classe
3	6	0	GDPR	MISC
1	6	0	LGPD	MISC
0	2	0	internet	MISC
2	6	0	Brasil	LOC
4	6	0	União Europeia	ORG

5.2.2 Conjunto de dados

pos	ADJ	ADP	ADV	AUX	CCONJ	DE	NOUN	NUM	PRO	PROP	PUNCT	SCONJ	VERB
count	167	155	57	33	61	94	345	5	29	12	120	39	173
unique	96	27	19	7	3	20	189	4	7	12	2	7	116
top	digital	de	não	é	e	A	segurança	uma	que	internet	,	pois	podem


pos	ADJ	ADP	ADV	AUX	CCONJ	DET	NOUN	NUM	PRON	PROPN	PUNCT	SCONJ	VERB
freq	15	41	10	20	49	24	23	2	20	1	80	13	9

5.2.3 Por documento

5.2.3.1 Gerais



	id	qtde sentenças	qtde palavras	qtde tokens	qtde palavras rassemstopword	qtde locverbo	qtde eventibo	qtde verbos aux	qtde substantivos	qtde verbos aux substantivos	qtde palavras desconhecidas	qtde ner
count	4000	40.0	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00
mean	20.50	1.0	32.25	38.17	19.73	3.85	4.33	5.15	8.62	13.78	4.25	0.15
std	11.69	0.0	5.71	8.07	4.24	1.35	1.46	1.44	2.29	2.77	2.11	0.66
min	100	1.0	23.00	26.00	13.00	1.00	1.00	3.00	4.00	7.00	1.00	0.00
25%	10.75	1.0	28.00	31.00	17.00	3.00	3.00	4.00	7.00	12.00	2.75	0.00

	id	qtde sentenças	qtde palavras	qtde tokens	qtde palavras stopwords	qtde locuções verbais	qtde verbos	qtde palavras auxiliares	qtde substantivos	qtde verbos auxiliares substantivos	qtde palavras desconhecidas	qtde erros
50%	20.50	1.0	31.50	36.50	18.00	4.00	4.00	5.00	8.00	13.00	4.00	0.00
75%	30.25	1.0	37.00	44.25	23.25	5.00	5.00	6.00	9.00	15.25	6.00	0.00
max	40.00	1.0	46.00	57.00	29.00	7.00	8.00	9.00	16.00	20.00	8.00	4.00




5.2.3.2 POS Tagging


	PR ON	VE RB	PUN CT	DE T	NO UN	AU X	CC ONJ	AD P	PRO PN	AD J	AD V	NU M	SCO NJ	SY M	SPA CE	IN TJ
count	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00
mean	0.72	4.33	3.00	2.35	8.62	0.82	1.52	3.88	0.30	4.17	1.43	0.12	0.97	0.00	0.00	0.00
std	0.68	1.46	1.11	1.33	2.29	0.64	0.88	1.91	0.88	1.87	1.24	0.33	0.70	0.00	0.00	0.00
min	0.00	1.00	1.00	0.00	4.00	0.00	0.00	0.00	0.00	2.00	0.00	0.00	0.00	0.00	0.00	0.00
25%	0.00	3.00	2.00	1.00	7.00	0.00	1.00	2.75	0.00	3.00	0.75	0.00	1.00	0.00	0.00	0.00
50%	1.00	4.00	3.00	2.00	8.00	1.00	1.00	3.50	0.00	4.00	1.00	0.00	1.00	0.00	0.00	0.00
75%	1.00	5.00	3.00	3.00	9.00	1.00	2.00	5.25	0.00	5.00	2.00	0.00	1.00	0.00	0.00	0.00
max	2.00	8.00	6.00	5.00	16.00	2.00	3.00	8.00	5.00	9.00	5.00	1.00	3.00	0.00	0.00	0.00



5.2.3.3 NER

	LOC	MISC	ORG	PER
count	40.00	40.00	40.00	40.0
mean	0.03	0.10	0.03	0.0
std	0.16	0.38	0.16	0.0
min	0.00	0.00	0.00	0.0
25%	0.00	0.00	0.00	0.0
50%	0.00	0.00	0.00	0.0
75%	0.00	0.00	0.00	0.0
max	1.00	2.00	1.00	0.0





5.2.3.4 Lista palavras

Lista as 20 palavras com maiores ocorrências no conjunto de dados.

, => 80

e => 49

de => 45

. => 40

a => 32

que => 30

A => 24

segurança => 23

em => 20

é => 20

digital => 15

um => 14

para => 14

pois => 13

cibernética => 12

da => 12

não => 10

dos => 9

informações => 9

como => 9

5.2.3.5 Lista palavras desconhecidas e ocorrências

Lista as 20 palavras desconhecidas pelo BERT com maiores ocorrência.

cibernética => ['ci', '##ber', '##n', '##ética'] => 12

comprometer => ['comprome', '##ter'] => 5

Empresas => ['Empresa', '##s'] => 4

eficazes => ['eficaz', '##es'] => 4

responsabilidade => ['responsa', '##bilidade'] => 4

conscientização => ['consci', '##ent', '##ização'] => 3

corporativas => ['corpo', '##rativas'] => 3

fortalecendo => ['fortale', '##cendo'] => 3

investem => ['invest', '##em'] => 3

senhas => ['sen', '##has'] => 3

autenticação => ['autent', '##icação'] => 2

causem => ['caus', '##em'] => 2

cibernéticos => ['ci', '##ber', '##n', '##éticos'] => 2

criptografia => ['cripto', '##grafia'] => 2

desempenham => ['desempenha', '##m'] => 2

estratégicas => ['estratégica', '##s'] => 2

indispensável => ['indispens', '##ável'] => 2

infraestruturas => ['infraestrutura', '##s'] => 2

monitoramento => ['monitora', '##mento'] => 2


seguras => ['segura', '##s'] => 2

5.2.4 Por sentença

5.2.4.1 Gerais



	id	se nte nc a	qtde pala vras	qtdet oken sbert	qtdepala vrassem stopword	qtde locv erbo	qtd eve rbo	qtde verb oaux	qtde substa ntivo	qtdeverb oauxsub stantivo	qtdepalav rasdesco nhecidas	qt de ne r
c o u n t	4000	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00
m e a n	2050	0.0	32.25	38.17	19.73	3.85	4.33	5.15	8.62	13.78	4.25	0.15
st d	1169	0.0	5.71	8.07	4.24	1.35	1.46	1.44	2.29	2.77	2.11	0.66
m in	1000	0.0	23.00	26.00	13.00	1.00	1.00	3.00	4.00	7.00	1.00	0.00
2 5 %	1075	0.0	28.00	31.00	17.00	3.00	3.00	4.00	7.00	12.00	2.75	0.00
5 0 %	2050	0.0	31.50	36.50	18.00	4.00	4.00	5.00	8.00	13.00	4.00	0.00

	id	se nte nc a	qtde pala vras	qtdet oken sbert	qtdepala vrassem stopword	qtde locv erbo	qtd eve rbo	qtde verb oaux	qtde substa ntivo	qtdeverb oauxsub stantivo	qtdepalav rasdesco nhecidas	qt de ne r
75%	30.25	0.0	37.00	44.25	23.25	5.00	5.00	6.00	9.00	15.25	6.00	0.00
max	40.00	0.0	46.00	57.00	29.00	7.00	8.00	9.00	16.00	20.00	8.00	4.00







5.2.4.2 POS Tagging



	PR ON	VE RB	PUN CT	DE T	NO UN	AU X	CC ONJ	AD P	PRO PN	AD J	AD V	NU M	SCO NJ	SY M	SPA CE	IN TJ
count	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00	40.00
mean	0.72	4.33	3.00	2.35	8.62	0.82	1.52	3.88	0.30	4.17	1.43	0.12	0.97	0.00	0.00	0.00
std	0.68	1.46	1.11	1.33	2.29	0.64	0.88	1.91	0.88	1.87	1.24	0.33	0.70	0.00	0.00	0.00
min	0.00	1.00	1.00	0.00	4.00	0.00	0.00	0.00	0.00	2.00	0.00	0.00	0.00	0.00	0.00	0.00
25%	0.00	3.00	2.00	1.00	7.00	0.00	1.00	2.75	0.00	3.00	0.75	0.00	1.00	0.00	0.00	0.00
50%	1.00	4.00	3.00	2.00	8.00	1.00	1.00	3.50	0.00	4.00	1.00	0.00	1.00	0.00	0.00	0.00
75%	1.00	5.00	3.00	3.00	9.00	1.00	2.00	5.25	0.00	5.00	2.00	0.00	1.00	0.00	0.00	0.00
max	2.00	8.00	6.00	5.00	16.00	2.00	3.00	8.00	5.00	9.00	5.00	1.00	3.00	0.00	0.00	0.00



5.2.4.3 Gráficos de POS Tagging nas sentenças dos documentos









5.2.4.4 NER

	LOC	MISC	ORG	PER
count	40.00	40.00	40.00	40.0
mean	0.03	0.10	0.03	0.0
std	0.16	0.38	0.16	0.0
min	0.00	0.00	0.00	0.0
25%	0.00	0.00	0.00	0.0
50%	0.00	0.00	0.00	0.0
75%	0.00	0.00	0.00	0.0
max	1.00	2.00	1.00	0.0








5.2.4.5 Gráficos NER nas sentenças dos documentos

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.





5.2.5 Por Janela

5.2.5.3 Estatísticas palavras e tokens por janela


	id	qtdepalavras	qtdetokenbert	qtdepalavrasjanela3	qtdepalavrasjanela5	qtdetokenbertjanela3	qtdetokenbertjanela5
count	40.00	40.00	40.00	40.00	40.00	40.00	40.00
mean	20.50	32.25	38.17	32.25	32.25	38.17	38.17
std	11.69	5.71	8.07	5.71	5.71	8.07	8.07
min	1.00	23.00	26.00	23.00	23.00	26.00	26.00
25%	10.75	28.00	31.00	28.00	28.00	31.00	31.00
50%	20.50	31.50	36.50	31.50	31.50	36.50	36.50
75%	30.25	37.00	44.25	37.00	37.00	44.25	44.25
max	40.00	46.00	57.00	46.00	46.00	57.00	57.00

5.2.5.4 Estatísticas palavras e tokens em janelas por documento


	id	qtde sentenças	qtde palavras	qtde tokens bert	total palavras janela3	total palavras janela5	total tokens bert janela3	total tokens bert janela5
count	40.00	40.0	40.00	40.00	40.00	40.00	40.00	40.00
mean	20.50	1.0	32.25	38.17	32.25	32.25	38.17	38.17
std	11.69	0.0	5.71	8.07	5.71	5.71	8.07	8.07
min	1.00	1.0	23.00	26.00	23.00	23.00	26.00	26.00
25%	10.75	1.0	28.00	31.00	28.00	28.00	31.00	31.00
50%	20.50	1.0	31.50	36.50	31.50	31.50	36.50	36.50
75%	30.25	1.0	37.00	44.25	37.00	37.00	44.25	44.25
max	40.00	1.0	46.00	57.00	46.00	46.00	57.00	57.00

5.2.6 Por Documento


5.2.6.1 Gráfico Quantidade de documentos por quantidade de sentenças




5.2.6.2 Gráfico Quantidade de documentos por quantidade de palavras




5.2.6.3 Gráfico Quantidade de documentos por quantidade de tokens



5.2.6.4 Gráfico Quantidade de documentos por quantidade de palavras desconsiderando as stopwords




5.2.6.5 Gráfico Quantidade de documentos por quantidade de locuções verbais




5.2.6.6 Gráfico Quantidade de documentos por quantidade de verbos

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.


INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




5.2.6.7 Gráfico Quantidade de documentos por quantidade de verbos(VERB) e verbos auxiliares(AUX)



5.2.6.8 Gráfico Quantidade de documentos por quantidade de substantivos(NOUN)




5.2.6.9 Gráfico Quantidade de documentos por quantidade de verbos(AUX) e substantivo(NOUN)




5.2.6.10 Gráfico Quantidade de documentos por quantidade de entidades reconhecidas

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



5.2.6.11 Gráfico da distribuição do comprimento dos documentos tokenizados




5.2.7 Por sentença


5.2.7.1 Gráfico Quantidade de sentenças de documentos por quantidade de palavras

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.


INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




5.2.7.2 Gráfico Quantidade de sentenças de documentos por quantidade de tokens




5.2.7.3 Gráfico Quantidade de sentenças de documentos por quantidade de palavras desconsiderando stopwords




5.2.7.4 Gráfico Quantidade de sentenças de documentos por quantidade de locuções verbais




5.2.7.5 Gráfico Quantidade de sentenças de documentos por quantidade de verbos(VERB)




5.2.7.6 Gráfico Quantidade de sentenças de documentos por quantidade de verbos(VERB) e verbos auxiliares(AUX)




5.2.7.7 Gráfico Quantidade de sentenças de documentos por quantidade de substantivos(NOUN)



5.2.7.8 Gráfico Quantidade de sentenças de documentos por quantidade de verbos(AUX) e substantivo



5.2.7.9 Gráfico Quantidade de sentenças de documentos por quantidade de entidades



3. Embeddings

3.1 *Word Embedding(pt-br) usando Word2Vec*

Exemplo de manipulação de de word embendding usando Word2Vec através da biblioteca Gensim Python Library com execução através do Google Colaboratory.

Programa executado corretamente.

3.2 - *BERT Embeddings pt-br usando Transformers by HuggingFace*

Mas, como era um exemplo não coloquei as tabelas e gráficos.

(Opcional)